

Segmentación de Células Cervicales en Imágenes del Conjunto SIPaKMeD

Camilo Moreno, Juan Muñoz, Santiago Mendivelso

September 2024

1 Introducción

El análisis de imágenes biomédicas se ha convertido en una herramienta crucial para la detección temprana de enfermedades, incluyendo el cáncer cervical. Los avances en técnicas de procesamiento de imágenes han permitido desarrollar algoritmos que segmentan y clasifican células en imágenes microscópicas con mayor precisión. En este proyecto, se aplicarán técnicas de segmentación de imágenes para aislar células cervicales utilizando el dataset SIPaKMeD, contribuyendo al desarrollo de métodos que faciliten la identificación de anomalías celulares. [1]

2 Segmentación

La segmentación es el proceso de dividir una imagen en sus partes o regiones constituyentes. El objetivo de la segmentación es simplificar o cambiar la representación de una imagen para que sea más significativa y más fácil de analizar. En términos simples, se trata de la partición de una imagen en regiones que son homogéneas con respecto a ciertas características, como el color, la intensidad o la textura. [2]

2.1 Tipos de segmentación

Algunos de los tipos de segmentación usados en imágenes y mencionados en el libro guía son:

- Umbralización: Se basa en separar los objetos del fondo utilizando un valor de umbral, donde los píxeles de una intensidad mayor o menor que el umbral pertenecen a diferentes regiones. [2]
- Segmentación basada en bordes: Este enfoque se centra en la detección de discontinuidades en la imagen para identificar las fronteras entre regiones. [2]

- Segmentación basada en regiones: Se agrupan píxeles que tienen propiedades similares, como la intensidad, para formar una región continua. [2]
- Segmentación por agrupamiento: Técnicas como K-means agrupan los píxeles en distintas categorías basadas en sus características. [2]

3 Contexto del problema

El cáncer cervical es una causa importante de mortalidad en mujeres a nivel mundial. Los exámenes de Papanicolaou permiten identificar células anormales, pero requieren tiempo y están sujetos a errores humanos. La identificación precisa de tipos celulares en el frotis depende de una segmentación efectiva que aísle las células del fondo, permitiendo clasificar células de manera fiable.[1]

El dataset SIPaKMeD contiene imágenes de cinco tipos de células cervicales: superficial-intermedia, parabasal, koilocítica, displásica y metaplásica. Este trabajo se enfoca en aplicar métodos de procesamiento para diferenciar cada tipo de célula a través de características visibles en los canales RGB. [1]

4 Problema

El principal problema es la segmentación automática de células cervicales en imágenes biomédicas, que presenta dificultades debido a las características visuales similares de las células y el ruido de fondo. Se busca implementar un método eficiente de segmentación que separe las células del fondo, mejorando la precisión de la clasificación posterior.

5 Actualización del contexto

En los últimos años, el análisis automatizado de imágenes biomédicas ha avanzado significativamente, especialmente en el ámbito de la citología cervical, donde las técnicas de procesamiento de imágenes y el aprendizaje automático han demostrado ser eficaces para la detección de células anormales y la identificación de lesiones precursoras de cáncer cervical. La segmentación y clasificación de células en imágenes de frotis de Papanicolaou sigue siendo un desafío debido a la variabilidad en las características morfológicas y texturales de las células, como el tamaño, la forma y la intensidad del color. [2]

Los enfoques tradicionales para la segmentación incluyen técnicas basadas en umbralización adaptativa y detección de bordes, que permiten diferenciar el núcleo y el citoplasma mediante el análisis de intensidad y color [4]. Sin embargo, estos métodos son limitados al enfrentarse a células solapadas o con bordes difusos, lo que ha llevado al desarrollo de algoritmos más avanzados, como la transformada Watershed, que proporciona una segmentación precisa en

casos de contacto entre células [5].

Recientemente, los métodos de aprendizaje profundo, como las redes neuronales convolucionales (CNN), han superado a los enfoques tradicionales en tareas de clasificación, aprovechando las características extraídas directamente de las imágenes RGB. Estos métodos permiten un análisis de textura y color en múltiples canales y han demostrado una alta precisión en la clasificación de células cervicales [6]. No obstante, debido al alto costo computacional y la necesidad de grandes cantidades de datos etiquetados, algunos estudios continúan explorando la integración de técnicas de preprocesamiento tradicionales combinadas con modelos de aprendizaje profundo para optimizar el rendimiento en conjuntos de datos más pequeños [1].

El dataset SIPaKMeD, publicado en 2018, se ha convertido en un recurso clave en este campo, proporcionando una base de datos de imágenes anotadas de cinco tipos de células cervicales. Este dataset ha permitido que numerosos estudios evalúen y comparen diferentes algoritmos de segmentación y clasificación, proporcionando una referencia estandarizada para el desarrollo de nuevas técnicas [1].

6 Descripción de Imágenes a Utilizar

Las imágenes del dataset SIPaKMeD fueron capturadas originalmente en alta resolución mediante una cámara CCD acoplada a un microscopio óptico OLYMPUS BX53F. Aunque algunas versiones se reducen a resoluciones menores (por ejemplo, 80x80 píxeles en experimentos con CNN), las imágenes originales son de alta resolución, lo que permite capturar detalles de núcleos, citoplasma y bordes celulares esenciales para el análisis citológico. [1]

Las imágenes están en formato RGB y contienen información de pigmentación en los canales de color, permitiendo un análisis detallado de la intensidad y textura que es fundamental para la segmentación y clasificación celular. [1]

7 Análisis del Dataset

En el dataset podemos encontrar las siguientes imágenes:

1. **Células normales:** Estas células se dividen en dos categorías: superficial-intermedia y parabasal. [1]

Superficial-Intermedia: Son células grandes, planas, con forma redonda, ovalada o poligonal. El citosol, la parte líquida del citoplasma de la célula es predominantemente eosinofílico o cianofílico (coloreado de rosa o azul, respectivamente). También podemos destacar que tienen un núcleo pequeño, central y

de tipo picnótico (denso y compacto). [1]

De estas células podemos destacar que tienen límites nucleares definidos y un citoplasma amplio y poligonal. Algunas de sus diferencias es que son el tipo más común de células en un frotis de Papanicolaou normal, mostrando cambios morfológicos característicos, como la atipia coilocítica en lesiones avanzadas, que puede señalar una infección por VPH (virus del papiloma humano). [1]

Parabasal: Son células epiteliales inmaduras, más pequeñas que las superficiales y con forma redondeada. El citosol es predominantemente cianofílico.

Su núcleo suele ser vesicular (de apariencia clara y no condensada) y de gran tamaño. Algunas de sus diferencias son que estas células tienen una morfología parecida a las células metaplásicas (benignas), aunque son difíciles de distinguir entre sí debido a sus características similares de tamaño y forma. [1]

2. Células Anormales: Estas células muestran cambios estructurales patológicos y se relacionan frecuentemente con infecciones por VPH. En este grupo encontramos las células koilocíticas y las células disqueratóticas. [1]

Koilocítica: Suelen ser células maduras (intermedias o superficiales), algunas de tipo metaplásico. Su coloración cianofílica suele ser muy clara, con una cavidad perinuclear grande y bordes del citoplasma muy densamente teñidos. [1]

Su núcleo es agrandado, con membranas nucleares irregulares y en muchos casos con múltiples núcleos (binucleadas o multinucleadas). Sus diferencias se evidencian principalmente en que son células patognomónicas de la infección por VPH, lo que significa que su presencia es indicativa de esta infección. La apariencia y tamaño del núcleo pueden variar según el estado de la infección y el tipo del virus. [1]

Disqueratótica: Estas son células escamosas que han sufrido queratinización prematura y anormal, y a menudo se encuentran en grupos tridimensionales. Su citosol: Presenta un color anaranjado brillante (eosinofílico) debido a la queratinización. [1] Núcleo: Vesicular, similar al de las células koilocíticas. Diferencias: Se distinguen por su disposición en grupos densos y gruesos, dificultando la identificación de los límites nucleares y citoplasmáticos. Como las koilocíticas, indican infección por VPH, y su presencia puede servir de indicador patognomónico en ausencia de células koilocíticas. [1]

3. Células Benignas: Estas células provienen de la zona de transformación del cuello uterino, donde suelen aparecer las lesiones precancerosas. [1]

Metaplásica: Pueden variar en tamaño, pero suelen ser células más pequeñas de tipo parabasal con bordes celulares bien definidos. Tienen una coloración marrón clara en la parte central y una coloración más oscura en los bordes. [1]

Su núcleo suele estar desplazado hacia un lado (excéntrico), y en ocasiones presenta una gran vacuola intracelular. A diferencia de las células parabásales, presentan una mayor uniformidad en el tamaño y forma, con un citoplasma casi redondo y oscuro en el centro. La presencia de estas células en el frotis se asocia con un riesgo más alto de detección de lesiones precancerosas (como lesiones escamosas intraepiteliales de alto grado, HSIL). [1]

7.1 Presentación gráfica del dataset




Figure 1: Superficial - intermedia




Figure 2: Parabasal



Figure 3: Koilocítica



Figure 4: Disqueratósica




Figure 5: Metaplástica

8 Propuesta para el procesamiento y segmentación de las imágenes del dataset

Para el análisis del dataset SIPaKMeD, se considerarán varios aspectos clave en las imágenes celulares, lo que requiere un enfoque de segmentación que permita diferenciar entre células normales y patológicas. Para llevar a cabo este análisis, es crucial identificar ciertas características visuales que nos permitan aplicar las transformaciones más apropiadas. Estas características incluyen:

- **Textura celular:** La textura de las células es una característica importante para diferenciar entre células normales y patológicas. Las células patológicas suelen presentar patrones irregulares o texturas más complejas que pueden destacarse a través del análisis de frecuencias espaciales. Esto será considerado para aplicar la Transformada Rápida de Fourier (FFT), que permitirá resaltar o eliminar texturas indeseadas en la imagen. [2]
- **Forma y tamaño de las células:** La forma y el tamaño son características clave para identificar grupos celulares. Las células patológicas pueden tener formas irregulares o estar superpuestas. Para segmentarlas, se usará el algoritmo Watershed, que permite separar eficientemente células que estén muy cercanas entre sí o que se encuentren superpuestas, detectando los bordes y dividiendo las regiones. [1], [8]
- **Contornos y límites celulares:** La claridad en los contornos de las células es esencial para un correcto proceso de segmentación. Para mejorar la identificación de los límites entre las células y el fondo, se utilizará el filtro de Canny, que resalta los bordes de las células, lo que facilita su posterior segmentación mediante el algoritmo Watershed. [2]
- **Información de color:** Las imágenes en el dataset SIPaKMeD están en color, lo que implica que la información del color puede ser relevante para

distinguir estructuras celulares o tejidos específicos. Para optimizar esta información sin perder detalle, se aplicará una Descomposición en Componentes Principales (PCA) en el espacio RGB. Esto permitirá reducir la dimensionalidad, preservando las variaciones de color más relevantes para el análisis y la clasificación de las células. [8]

Este enfoque integral basado en el análisis del color, los bordes, el núcleo y la morfología celular externa tiene como objetivo mejorar la precisión en la segmentación de las células.

9 Posible resultado

Para realizar nuestro objetivo de segmentar las células utilizaremos los siguientes métodos:

- Transformada de Fourier: La transformada rápida de Fourier (FFT) nos permite analizar la frecuencia espacial de la imagen, lo que es útil para varios propósitos en el procesamiento de imágenes. Puede ser utilizada para mejorar el contraste, eliminando patrones repetitivos o ruido en ciertas frecuencias. También es útil para la umbralización basada en frecuencias, donde se filtran componentes indeseables o se resaltan ciertas estructuras.[2]
- Algoritmo Watershed: Este algoritmo es eficaz para separar células que están superpuestas o muy cercanas entre sí. Se basa en un enfoque de detección de contornos mediante la simulación de un flujo de agua que "inunda" la imagen, separando las células en regiones distintas. [3]
- Filtros de Detección de Bordes (Canny): El filtro Canny puede utilizarse para resaltar los bordes de las células, ayudando a mejorar la detección de los contornos celulares. Estos bordes pueden luego combinarse con el método Watershed para una segmentación más precisa. [2]
- Descomposición en Componentes Principales (PCA) en el Espacio RGB: Este enfoque se utiliza para reducir la dimensionalidad de la imagen combinando los tres canales RGB en componentes principales. Esto permite optimizar la representación de color, preservando las variaciones más relevantes, y simplifica el procesamiento de la imagen. [7]

10 Referencias Bibliográficas

1. Plissiti, M. E., Dimitrakopoulos, P., & Nikou, C. (2018). SIPaKMeD: A New Dataset for Feature and Image-Based Classification of Normal and Pathological Cervical Cells in Pap Smear Images [Dataset]. IEEE Dataport. <https://doi.org/10.21227/H29W-9H39>

2. Gonzalez, R. C., & Woods, R. E. (2017). *Digital Image Processing* (4th ed.). Pearson Education.
3. Roerdink, J. B., & Meijster, A. (2000). *The Watershed Transform: Definitions, Algorithms and Parallelization Strategies*. *Fundamenta Informaticae*, 41(1-2), 187-228.
4. M. H. Tsai, Y. K. Chan, Z. Z. Lin, S. F. Yang-Mao, and P. C. Huang, “Nucleus and cytoplasm contour detector of cervical smear image,” *Pattern Recognition Letters*, vol. 29, pp. 1441–1453, 2008.
5. J. B. Roerdink and A. Meijster, “The watershed transform: definitions, algorithms and parallelization strategies,” *Fundamenta Informaticae*, vol. 41, no. 1-2, pp. 187-228, 2000.
6. A. Krizhevsky, I. Sutskever, and G. E. Hinton, “Imagenet classification with deep convolutional neural networks,” in *Advances in Neural Information Processing Systems (NIPS)*, 2012, pp. 1097–1105.
7. IBM, “PCA,” *Ibm.com*, Dec. 04, 2023. <https://www.ibm.com/es-es/topics/principal-component-analysis>
8. Vincent, L., & Soille, P. (1991). Watersheds in Digital Spaces: An Efficient Algorithm based on Immersion Simulations. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 13(6), 583-598.